

UNIVERSIDADE DE SÃO PAULO
INSTITUTO DE CIÊNCIAS MATEMÁTICAS E DE COMPUTAÇÃO

DEPARTAMENTO DE CIÊNCIAS DE COMPUTAÇÃO

<http://www.icmc.usp.br>

SCC0275 - Introdução à Ciência de Dados

Prof. Dra. Roseli Aparecida Francelin Romero

Análise da Felicidade ao Redor do Mundo

Observações de 2007 a 2023

Amanda Valukas Breviglieri Joioso - 4818232

Mariana Kaori Randig Ekuni - 12675722

Paulo Henrique Vedovatto Turquetti - 13750791

São Carlos - SP

Novembro de 2024

Sumário

1. Links	2
2. Introdução	2
3. Trabalhos Relacionados	3
4. Material e Métodos	4
A) Apresentação do DataSet	4
B) Exploração e Pré-processamento	4
Hipóteses Iniciais	4
Tratamento de Valores Ausentes e Exclusão de Entradas	5
Normalização de Dados	5
Transformação de Dados	5
C) Extração de Características e Seleção de Atributos	6
D) Modelos de Regressão Utilizados	6
E) Implementação dos Modelos de Regressão	7
Regressão Linear	7
Random Forest	7
Decision Tree	7
KNN	8
Métricas de Desempenho	8
5. Experimentos	9
A) Experimentos Realizados	9
Análise de BoxPlots	9
Matriz de Correlação	11
Análise da Felicidade na Atualidade	12
Impactos da Pandemia da COVID-19 na Felicidade	14
Tendência de Felicidade	16
Previsão de Life Ladder com Modelos de Regressão	19
6. Conclusão	22
7. Referências	24

1. Links

Esta seção apresenta os recursos utilizados para a realização das análises e experimentos descritos. O primeiro recurso é o [Notebook Google Colab](#), que contém todo o código desenvolvido para o trabalho. Nele, estão detalhadas as etapas do pré-processamento, incluindo a normalização dos dados e o tratamento de valores nulos, além das implementações de análise exploratória e dos modelos de aprendizado de máquina.

O segundo recurso é a [Base de Dados no Kaggle](#), intitulada *World Happiness Report - 2024 Yearly Updated Dataset*. Esta base compila dados sobre felicidade global de 2005 a 2023, oferecendo informações valiosas sobre variáveis econômicas, sociais e de percepção subjetiva de bem-estar, como PIB per capita, suporte social, expectativa de vida saudável, liberdade de escolha, generosidade e percepção de corrupção. Esses dados foram fundamentais para o desenvolvimento do estudo, permitindo a investigação das relações entre essas variáveis e a felicidade global, além de viabilizar a construção de modelos preditivos robustos.

2. Introdução

O *World Happiness Report* [1] é uma iniciativa global que analisa e classifica o nível de felicidade em diferentes países ao redor do mundo. Criado com o objetivo de compreender os fatores que influenciam o bem-estar e a qualidade de vida das populações, o relatório serve como um guia para a formulação de políticas públicas e estratégias que promovam uma sociedade mais equilibrada e feliz.

Embora a felicidade seja uma métrica subjetiva, a resolução da Assembleia Geral das Nações Unidas intitulada *"Happiness: Towards a Holistic Approach to Development"* incentiva os países a considerarem a felicidade como um indicador essencial para o desenvolvimento social e econômico. Esse enfoque destaca a relevância de estudar como diferentes fatores, como suporte social, PIB per capita e liberdade de escolha, impactam a percepção de felicidade ao redor do mundo.

O presente trabalho tem como objetivo realizar uma análise do índice de felicidade (*Ladder Score*) entre países e regiões, identificar tendências de felicidade ao longo do tempo, avaliar os impactos da pandemia de COVID-19 nos índices de felicidade e desenvolver modelos preditivos do índice de felicidade baseados nas variáveis disponíveis na base de dados.

As análises incluem visualizações dos índices de felicidade por país e região, bem como comparações entre períodos pré-pandemia e pós-pandemia para avaliar mudanças ocasionadas pela COVID-19. Para identificar tendências ao longo do tempo, foi empregada a técnica de regressão linear. Por fim, modelos preditivos de felicidade foram desenvolvidos utilizando Regressão Linear e Random Forest, avaliados por meio de métricas como R^2 , Erro Médio Absoluto (MAE) e Erro Quadrático Médio (RMSE).

Este trabalho está organizado nas seguintes seções:

1. **Trabalhos Relacionados** – Apresenta estudos que utilizaram a mesma base de dados, destacando as técnicas aplicadas e suas contribuições.
2. **Materiais e Métodos** – Detalha o conjunto de dados, as etapas de pré-processamento e exploração, e as configurações dos modelos de aprendizado de máquina.

3. **Experimentos** – Descreve os experimentos realizados, os parâmetros ajustados, os modelos testados e os resultados obtidos.
4. **Conclusão** – Resume os principais resultados e analisa o desempenho das técnicas aplicadas.

3. Trabalhos Relacionados

Nesta seção, apresentamos outros trabalhos que exploraram a base de dados **World Happiness Report (WHR)** e implementaram técnicas de aprendizado de máquina para prever ou analisar os fatores que influenciam os índices de felicidade ao redor do mundo.

No artigo “*Predicting Happiness Index Using Machine Learning*” [2], foram utilizadas as bases de dados do WHR referentes aos anos de 2018 e 2019. Os autores compararam diferentes algoritmos de regressão, incluindo **XGBoost**, **Random Forest** e **Lasso Regression**, obtendo o melhor desempenho com o XGBoost, que alcançou um R^2 de 85,03% e um MSE de 0,0032. O Random Forest apresentou resultados ligeiramente inferiores (R^2 de 83,68% e MSE de 0,0035), enquanto o Lasso Regression teve o pior desempenho entre os três (R^2 de 80,61% e MSE de 0,0041). Esse trabalho destaca a eficácia do XGBoost para lidar com dados não linearmente separáveis e identificar padrões complexos na base WHR.

Outro estudo, “*Predicting Quality of Life using Machine Learning: case of World Happiness Index*” [3], utilizou a base do WHR de 2021 e implementou diversos algoritmos, incluindo **Lasso Regression**, **Multiple Linear Regression**, **LSTM**, **Random Forest**, **Support Vector Regression**, **Gradient Boosting**, **XGBoost**, **MLP** e **AdaBoost**. O Lasso Regression se destacou, apresentando um R^2 de 89,54% e um MSE de 0,0043, enquanto os demais algoritmos tiveram desempenho progressivamente inferior. Este trabalho explorou um amplo conjunto de técnicas, reforçando a versatilidade e a eficácia do Lasso Regression para tarefas de previsão na base WHR.

Além desses estudos, o trabalho intitulado “*The Happiness Equation*” [4], disponível no Kaggle, aborda a exploração de dados e a engenharia de características na base WHR. Embora o foco principal tenha sido a análise exploratória e o pré-processamento, o autor implementou modelos básicos de regressão, como **Linear Regression** e **Decision Trees**, com resultados preliminares que indicam a importância de atributos como **Log GDP per capita** e **Social Support** na predição do índice de felicidade. Apesar de não ser uma abordagem tão robusta quanto as anteriores, este estudo contribui para a compreensão da relevância de diferentes variáveis no WHR.

O presente trabalho se diferencia ao utilizar os dados de 2007 a 2023 do *World Happiness Report*, permitindo análises mais complexas da felicidade, explorando o impacto da pandemia de COVID-19 no índice de felicidade e realizando uma comparação entre os métodos de **Regressão Linear**, **Random Forest**, **Decision Tree** e **KNN**.

4. Material e Métodos

A) Apresentação do DataSet

Essa pesquisa irá utilizar a base de dados [World Happiness Report - 2024](#), composta por informações coletadas na pesquisa O Relatório Mundial da Felicidade, uma parceria entre a Gallup, o Oxford Wellbeing Research Centre, a Rede de Soluções para o Desenvolvimento Sustentável da ONU e o Conselho Editorial do WHR, dos anos de 2007 a 2023. A base de dados conta com um total de **2363 valores de entradas** (linhas) e **12 atributos** (colunas), sendo eles:

- **Country name:** Nome do país (categórico).
- **Year:** Ano em que os dados foram registrados (numérico)
- **Ladder score:** A pontuação de felicidade para cada país, com base nas respostas à pergunta Cantril Ladder, que pede aos entrevistados que pensam em uma escala, sendo a melhor vida possível para eles 10 e a pior vida possível 0 (numérico).
- **Log GDP per capita:** O logaritmo natural do PIB per capita do país, ajustado pela paridade do poder de compra (PPC) para ter em conta as diferenças no custo de vida entre os países (numérico).
- **Social support:** A média nacional de respostas binárias (0 ou 1 representando Não/Sim) à pergunta sobre ter parentes ou amigos com quem contar em momentos de dificuldade (numérico).
- **Healthy life expectancy:** O número médio de anos que um recém-nascido viveria com boa saúde, com base nas taxas de mortalidade e na esperança de vida em diferentes idades (numérico).
- **Freedom to make life choices:** Média nacional de respostas à questão sobre a satisfação com a liberdade de escolher o que fazer da vida (numérico).
- **Generosity:** A exceção da regressão da média nacional de respostas à questão sobre doar dinheiro para instituições de caridade sobre o PIB per capita (numérico).
- **Perceptions of corruption:** A média nacional de respostas a perguntas sobre a extensão percebida da corrupção no governo e nas empresas (numérico).
- **Positive affect:** A média nacional de respostas a perguntas sobre emoções positivas vividas no dia anterior à pesquisa (numérico).
- **Negative affect:** A média nacional de respostas a perguntas sobre emoções negativas vividas no dia anterior à pesquisa (numérico).
- **Regional indicator:** Região a qual o país pertence (categórico).

B) Exploração e Pré-processamento

Hipóteses Iniciais

Durante a etapa de exploração inicial dos dados, foram geradas as seguintes hipóteses iniciais:

- Países com maior PIB per capita tendem a ser mais felizes e, em decorrência disso, países mais ricos são mais felizes.
- A pandemia da COVID-19 impactou negativamente a felicidade no mundo
- A maioria dos países possuem uma tendência de felicidade positiva
- Experiências positivas no dia anterior à pesquisa impactam fortemente a percepção de felicidade, do mesmo modo que experiências negativas impactam negativamente.
- A percepção de corrupção impacta negativamente a felicidade de um país.
- Países com maior liberdade para tomar decisões de vida são mais felizes.
- O PIB per capita é a variável que mais influencia o índice de felicidade

Tratamento de Valores Ausentes e Exclusão de Entradas

Analisando a base de dados, percebe-se que os anos de 2005 e 2006 possuem um número de entradas muito menor do que em outros anos analisados, de modo que, enquanto esses anos possuem menos de 30 entradas, os outros anos possuem acima de 100. Sendo assim, as entradas desses anos serão desconsideradas, visando a redução de viés, melhor comparabilidade e aumento na qualidade da análise. Com isso, serão analisados um total de 164 países, com dados no intervalo entre o ano de 2007 a 2023. É importante ressaltar que existem países analisados que não possuem dados em determinados anos desse intervalo.

A base de dados contém um total de **332 valores ausentes**, sendo todos em colunas numéricas. Após gerar boxplots para os atributos numéricos, nota-se a existência de uma grande quantidade de outliers capazes de distorcer a média desses valores. Sendo assim, para fazer o tratamento de valores ausentes, iremos substituir esses valores nulos pela **mediana** do atributo, já que essa é menos sensível a valores extremos e fornece uma representação mais robusta da tendência central dos dados quando comparada à média.

Normalização de Dados

Foi aplicada a **normalização** dos valores numéricos utilizando **MinMaxScaler.fit_transform** visando impedir que atributos com maior escala impactam negativamente o desempenho de modelos que dependem do cálculo de distâncias, como o KNN. Com isso, todos os dados encontram-se no intervalo [0, 1].

Transformação de Dados

Durante a aplicação dos modelos de Aprendizado de Máquina iremos realizar primeiramente o treinamento dos modelos ignorando o atributo categórico 'Regional indicator' e comparar os resultados obtidos com os mesmos modelos agora utilizando esse atributo no treinamento.

Sendo assim, para que '**Regional indicator**' pudesse ser utilizado na etapa de treino dos modelos, sabendo que esse é um atributo categórico com 11 possíveis valores, foi criada uma cópia do data frame e nela foi aplicado o método **OneHotEncoder** da biblioteca sklearn,

transformando a coluna ‘Regional indicator’ em 11 colunas categóricas binárias que indicam se o país pertence ou não à região referente ao atributo.

C) Extração de Características e Seleção de Atributos

Ao fazer o download do DataSet, são encontrados 2 arquivos:

- **World-happiness-report-updated_2024.csv** - Contém os dados coletados nas pesquisas World Happiness Report em todos os anos de realização
- **World-happiness-2024.csv** - Contém apenas os dados da pesquisa lançada em 2024, porém com a adição do atributo “Regional indicator”, que indica a qual região o país pertence.

A fim de obter a região de cada país analisado, foi feito um merge entre o dataset obtido em **World-happiness-report-updated_2024.csv** (arquivo completo) com um dataset de regiões gerado a partir de **World-happiness-2024.csv** (segundo documento), inserindo o valor “Unknown” a Regional Indicator onde não houve correspondência entre país e região. Sendo assim, tivemos como resultado a adição de uma nova coluna que demonstra a região do país, bastante utilizada em análises feitas nesta pesquisa.

Buscando analisar a existência de atributos redundantes, irrelevantes ou altamente correlacionados, foi gerada a matriz de correlação dos atributos numéricos da base de dados. A partir da análise da matriz, foi possível identificar a inexistência de redundância nos atributos e uma correlação significativa por parte de todas as variáveis presentes no dataset. Sendo assim, **não houve a exclusão de nenhum atributo**, decisão fortalecida pela baixa quantidade de atributos presente no dataset.

D) Modelos de Regressão Utilizados

Nesse projeto, serão utilizadas técnicas de aprendizado de máquina visando prever o índice de felicidade (“Life Ladder”) a partir das variáveis independentes. Em um primeiro momento os modelos foram treinados sem incluir a variável ‘Regional indicator’. Após isso, esse atributo foi transformado e incluindo no treinamento dos mesmos modelos utilizados, comparando os resultados obtidos. Sendo assim, serão implementados dois modelos de regressão, sendo eles:

- Regressão Linear
- Random Forest
- Decision Tree
- KNN

E) Implementação dos Modelos de Regressão

Para a implementação dos modelos de aprendizado de máquina, os dados foram separados em dois conjuntos, sendo eles:

- **X** - Variáveis independentes. Contém todos os atributos exceto “Country name”, “year”, “Regional indicator” e “Life Ladder”. Em um segundo momento, o atributo ‘Regional indicator’ foi transformado para ser incluído no treinamento dos modelos
- **y** - Variável dependente, representada pelo atributo alvo “Life Ladder”

A separação dos dados em treinamento e teste foi realizada utilizando **K-Fold** em todos os modelos de regressão. Em vez de depender de uma única divisão de treino e teste, o K-Fold garante que todos os dados sejam usados tanto para treino quanto para validação, proporcionando uma visão mais ampla da qualidade do modelo e melhorando a confiabilidade dos resultados. Sendo assim, definindo **k = 10**, os dados são divididos em 10 partes iguais, utilizando uma parte para validação e as outras para treino, repetindo o processo até que todas as partes tenham sido usadas como validação, obtendo um equilíbrio entre eficiência computacional, variância da estimativa e confiabilidade nos resultados. As variáveis de análise de desempenho são calculadas a partir da média dos resultados obtidos em cada divisão dos dados em treino-teste.

Regressão Linear

Para a implementação da regressão linear, foi utilizado o modelo **LinearRegression** da biblioteca scikit-learn, buscando encontrar a melhor relação linear entre as variáveis independentes (X) e a variável dependente (y), prevendo um valor contínuo para “Life Ladder”. Para ampliar o desempenho do modelo, foi utilizada a técnica de validação cruzada K-Fold, configurada com `n_splits=10` (10 folds),

Random Forest

O modelo Random Forest Regressor foi utilizado para prever a variável contínua Life Ladder, que representa o índice de felicidade dos países. O modelo foi instanciado usando a classe RandomForestRegressor da biblioteca scikit-learn com os seguintes parâmetros principais:

- `n_estimators=100`: Define o número de árvores na floresta.
- `random_state=42`: Garante que os resultados sejam reprodutíveis

Para uma avaliação mais robusta, também foi empregada a técnica de validação cruzada K-Fold com 10 divisões (`cv=10`). Após o treinamento do modelo, foi realizada a análise da relevância das variáveis na Random Forest.

Decision Tree

O modelo Decision Tree Regressor foi utilizado para prever a variável contínua configurado com a classe DecisionTreeRegressor da biblioteca scikit-learn.

- `random_state=42`: Garante reprodutibilidade dos resultados.

O hiperparâmetro `max_depth` não foi ajustado, de modo a permitir que a árvore não seja limitada a uma profundidade máxima. Para uma análise robusta do desempenho, foi empregada a técnica de validação cruzada K-Fold com `k=10`.

KNN

O modelo de Aprendizado de Máquina KNN foi o último modelo utilizado para prever o Life Ladder, configurado com a classe `KNeighborsRegressor` da biblioteca `scikit-learn`. Foi utilizado `k = 4` devido ao melhor desempenho apresentado. Também foi utilizada a validação cruzada K-Fold com `k = 10` para a divisão dos dados em treinamento e teste.

Métricas de Desempenho

O desempenho dos modelos de regressão desenvolvidos foi analisado a partir das seguintes métricas:

1. **R^2** : Mede a proporção da variância explicada pelo modelo em relação aos dados.
2. **MAE (Mean Absolute Error)**: Calcula o erro absoluto médio entre os valores previstos e os valores reais
3. **RMSE (Root Mean Squared Error)**: Mede o erro médio quadrático entre os valores previstos e os reais, penalizando mais fortemente erros maiores


Em todos os modelos, os valores das métricas foram calculados para cada um dos 10 folds, e as médias de cada métrica representam o desempenho do modelo.


Como dito anteriormente, os modelos serão treinados inicialmente sem o indicador e depois incluindo colunas 'Regional indicator'. Sendo assim, essas três métricas serão utilizadas para comparar o impacto do uso do indicador de região na previsão do índice de felicidade.

5. Experimentos

A) Experimentos Realizados

Análise de BoxPlots






Os boxplots fornecem uma boa visão geral das distribuições de diversas variáveis na nossa base de dados. A seguir, analisamos cada uma delas:

- Life Ladder: O boxplot de Life Ladder revela que a maioria das pontuações de felicidade estão concentradas entre 4,7 e 6,3, com a mediana em torno de 5,5. Esses valores indicam uma tendência de felicidade relativamente baixa para a maioria dos casos na base de dados.
- Log GDP per capita: Para o Log GDP per capita, a distribuição está concentrada entre 8,5 e 10,4, com a mediana próxima a 9,5, sugerindo que a maioria dos países da base de dados têm PIB per capita dentro dessa faixa.
- Social Support: O boxplot de Social Support mostra que a maioria dos valores estão entre 0,74 e 0,91, com uma mediana em 0,83. No entanto, há uma quantidade significativa de outliers abaixo da cerca inferior, indicando a presença de valores extremos.
- Healthy life expectancy at birth: Para Healthy life expectancy at birth, a maioria dos valores está entre 59 e 68 anos, com uma mediana de 65 anos. Similarmente, observamos outliers abaixo da cerca inferior, que indicam valores extremos mais baixos.
- Freedom to make life choices: A variável Freedom to make life choices mostra a maioria dos valores entre 0,67 e 0,87, com uma mediana em torno de 0,78. Assim como nas outras variáveis, há outliers abaixo da cerca inferior.
- Generosity: O boxplot de Generosity revela que a maioria dos valores está entre -0,13 e +0,09, com a mediana em -0,02. Há também a presença de outliers significativos acima da cerca superior, sugerindo valores extremos altos.
- Perceptions of corruption: A variável Perceptions of corruption apresenta a maioria dos valores entre 0,68 e 0,87, com uma mediana de cerca de 0,8, embora existam outliers abaixo da cerca inferior.
- Positive affect: No boxplot de Positive affect, a maioria dos valores está entre 0,57 e 0,73, com uma mediana em torno de 0,67. Também são observados alguns outliers abaixo da cerca inferior.

- Negative affect: Por fim, para Negative affect, a maioria dos valores está entre 0,21 e 0,33, com a mediana em 0,27. No entanto, a presença de outliers acima da cerca superior também é notável.

Matriz de Correlação



Com a análise da matriz de correlação, podemos tirar que os 12 pares mais correlacionados são os seguinte:

- Healthy life expectancy at birth e Log GDP per capita = 0,82
- Life Ladder e Log GDP per capita = 0,77
- Life Ladder e Social Support = 0,72
- Healthy life expectancy at birth e Life Ladder = 0,71
- Log GDP per capita e Social support = 0,68
- Healthy life expectancy at birth e Social support = 0,61
- Freedom to make life choices e Positive affect = 0,58
- Freedom to make life choices e Life Ladder = 0,53
- Life Ladder e Positive affect = 0,51
- Negative affect e Social support = -0,46
- Freedom to make life choices e Perceptions of corruption = -0,44
- Life Ladder e Perceptions of corruption = -0,41


Os 9 primeiros pares têm correlação positiva, o que indica que as duas variáveis tendem a se mover na mesma direção. Os 3 últimos têm uma correlação negativa, o que significa que as duas variáveis tendem a se mover em direções opostas.

Além disso, a partir dessa análise podemos tirar algumas variáveis que têm forte correlação direta com o atributo de Life Ladder (que representa a pontuação de felicidade de um país de 0 a 10):

- Log GDP per capita (0,77)
- Social support (0,72)
- Healthy life expectancy at birth (0,71)
- Freedom to make life choices (0,53)
- Positive affect (0,51)
- Perceptions of corruption (-0,41)

Análise da Felicidade na Atualidade

A fim de identificar a distribuição da felicidade ao redor do globo no contexto atual, será calculada a média dos valores “Life Ladder” registrados no período de 2020 a 2023 agrupados por país, oferecendo uma boa representação do estado de felicidade ao redor do globo.



Média do Life Ladder por país: 5.52659

Mediana do Life Ladder por país: 5.71300

Analisando os 10 países que apresentaram a **maior média** de Life Ladder entre 2020 e 2023:

1. Finlândia: 7.777
2. Dinamarca: 7.565
3. Islândia: 7.537
4. Holanda: 7.365
5. Suécia: 7.336
6. Israel: 7.304
7. Noruega: 7.299

8. Suíça: 7.172
9. Luxemburgo: 7.122
10. Nova Zelândia: 7.086


Percebemos que todos os 5 países nórdicos (Finlândia, Dinamarca, Islândia, Suécia e Noruega), estão entre os países mais felizes. Além disso, todos os países, com exceção de Israel e Nova Zelândia, estão localizados no continente europeu.

Agora, iremos analisar os 10 países com a **menor média** de Life Ladder no período analisado:

1. Afeganistão: 1.721
2. Líbano: 2.688
3. Lesoto: 3.186
4. Serra Leoa: 3.247
5. Congo: 3.295
6. Zimbábue: 3.295
7. Botsuana: 3.383
8. Malawi: 3.421
9. Essuatíni: 3.502
10. Iêmen: 3.561

Entre 10 países menos felizes no período analisado, 3 fazem parte do Oriente Médio (Afeganistão, Líbano e Iêmen), enquanto os outros 7 estão no continente africano (Lesoto, Serra Leoa, Congo, Zimbábue, Botsuana, Malawi e Essuatíni).

Analisando o mapa, é possível notar que existe uma proximidade entre os valores de Life Ladder de um país e seus vizinhos, além de existir uma certa tendência a valores próximos nos países de um mesmo continente ou região. Sendo assim, foi feito um agrupamento por região utilizando o atributo '**Regional indicator**'. Os resultados obtidos foram calculados a partir da média dos valores de Life Ladder dos países contidos na região.



A região com melhor índice de felicidade são os países da América do Norte, Austrália e Nova Zelândia, seguido pelo Oeste Europeu e, em terceiro colocado, a Europa Central e Leste Europeu. Enquanto isso, as regiões com pior índice de felicidade são o Sul Asiático e a África Sub-Saariana.

Obs: A região “Unknown” é composta por 21 países nessa análise, de modo que a maioria deles pertence ao Oriente Médio, Norte da África e África-Sub-Saariana.

Impactos da Pandemia da COVID-19 na Felicidade

Para analisar o impacto da pandemia da COVID-19 na felicidade dos países, iremos considerar os de 2018 e 2019 como pré-pandemia e 2020 e 2021 como pós início da pandemia. Com isso, iremos calcular o Life Ladder médio de cada período:

$$LifeLadder_PréPandemia = (LadderScore2018 + LadderScore2019) / 2$$


$$LifeLadder_PósPandemia = (LadderScore2020 + LadderScore2021) / 2$$

A partir disso, é possível calcular o valor da diferença entre essas médias, dada por:

$$Diferença = LadderScore_PósPandemia - LadderScore_PréPandemia$$

De modo que, se:

- Diferença > 0: País tornou-se mais feliz após a pandemia
- Diferença < 0: País tornou-se menos feliz após a pandemia



Média da diferença do Life Ladder por país pré e pós pandemia: -0.038784


Mediana da Diferença do Life Ladder por país pré e pós pandemia: -0.00349

A seguir estão os 10 países com **maior valor de ‘Diferença’**, ou seja, que apresentaram os **maiores crescimentos da felicidade** no período da pandemia da COVID-19 (2020-2021).

1. Croácia: 0.817
2. China: 0.680
3. Malásia: 0.629
4. Ucrânia: 0.609
5. Romênia: 0.527
6. Lituânia: 0.442
7. Estônia: 0.441
8. Argélia: 0.434
9. Quirguistão: 0.416
10. Bulgária: 0.407

Agora, os 10 países com **menor valor de ‘Diferença’**, ou seja, que apresentaram os maiores **decrescimentos da felicidade** no período da pandemia da COVID-19 (2020-2021).

1. Líbano: -2.189
2. Benim: -0.948
3. Bahrein: -0.925
4. Costa Rica: -0.697
5. Jamaica: -0.690
6. Colômbia: -0.668
7. Camboja: -0.594
8. Equador: -0.574
9. Filipinas: -0.546
10. Jordânia: -0.545



Com esses dados, percebemos que levando em conta os países que possuem entradas no período de anos analisado, houve um decaimento médio de 0.03875 no índice de felicidade e uma mediana de -0.003, indicando que a maioria dos países analisados tornaram-se menos felizes no período pós-pandêmico. Isso pode sugerir que a pandemia da COVID-19 não resultou em uma mudança significativa na felicidade dos países. No entanto, quando é realizada a análise por região, percebemos que esse impacto não foi uniforme.

Enquanto as regiões Leste Europeu e Europa Central, Leste Asiático e Comunidade de Estados Independentes (Armênia, Azerbaijão, Geórgia, Cazaquistão, Quirguistão, Moldávia, Rússia, Tajiquistão, Ucrânia e Uzbequistão) apresentaram um crescimento da felicidade após o início da pandemia da COVID-19, as outras regiões tornaram-se menos felizes nesse período. As regiões que mais sofreram impacto foram América Latina e Caribe e Oriente Médio e Norte Africano.



Obs: Apesar de ter apresentado o maior decréscimo, a região **Unknown**, que representa países sem o indicador regional foi desconsiderada dessa análise, já que era composta apenas pelos dados da Turquia.

Tendência de Felicidade

Ao calcular a regressão linear para o índice de felicidade ao longo do tempo, foi possível estimar como a felicidade tem evoluído em diferentes países. O coeficiente da reta gerada pela regressão linear representa a taxa de mudança no índice de felicidade para cada país ao longo dos anos.


- **Coeficiente positivo:** Países com coeficientes positivos indicam uma tendência crescente na felicidade, ou seja, esses países têm apresentado uma melhora ao longo do tempo.
- **Coeficiente negativo:** Países com coeficientes negativos indicam uma tendência decrescente, ou seja, esses países têm se tornado progressivamente menos felizes.

Vale destacar que esse coeficiente não representa a felicidade de um país em termos absolutos, mas sim a sua tendência de crescimento ou declínio no índice de felicidade. A seguir, iremos analisar os dados relativos à tendência.



Média da Tendência por país: 0.07809

Mediana da Tendência por país: 0.06137





Abaixo estão listados os **10 países com maior tendência de crescimento na felicidade**, ou seja, os que têm experimentado um aumento mais significativo na felicidade ao longo do tempo (coeficientes positivos):


1. Sérvia: coeficiente 2,13
2. Bulgária: coeficiente 1,96
3. Guiné: coeficiente 1,72
4. Romênia: coeficiente 1,71
5. Letônia: coeficiente 1,70
6. Togo: coeficiente 1,60
7. Hungria: coeficiente 1,58
8. República do Congo (Brazzaville): coeficiente 1,57
9. Costa do Marfim: coeficiente 1,53
10. Kosovo: coeficiente 1,49

Esses países têm mostrado uma melhora constante na felicidade, com os valores de felicidade aumentando ao longo dos anos. Por outro lado, os **10 países com maior tendência de queda na felicidade** (coeficientes negativos) são:

1. Afeganistão: coeficiente -2,80
2. Síria: coeficiente -2,46
3. Líbano: coeficiente -2,42
4. Venezuela: coeficiente -2,10
5. Angola: coeficiente -1,74
6. Jordânia: coeficiente -1,71
7. Malawi: coeficiente -1,54
8. Lesoto: coeficiente -1,49
9. Zâmbia: coeficiente -1,39
10. Botsuana: coeficiente -1,28

Esses países estão apresentando uma diminuição significativa da felicidade ao longo dos anos, com os valores de felicidade caindo consistentemente. Abaixo seguem os gráficos dos países com maior e menor tendência, respectivamente:





A partir desses dados, podemos perceber que a maioria dos países possuem uma tendência positiva. Isso significa que, com o passar dos anos, os países tendem a apresentar um crescimento no índice de felicidade “Life Ladder”, tornando-se mais felizes.

No entanto, é possível verificar que a distribuição da tendência é bastante desigual quando a análise é feita por região. Enquanto a região “Central and Eastern Europe”, “Commonwealth of Independent States” e “East Asia” apresentam uma tendência significativamente positiva, marcado por um grande aumento da felicidade no decorrer dos anos, as regiões “Middle East and North Africa”, “South Asia” e “North America and ANZ” (região mais feliz entre 2020 e 2023, analisada anteriormente) possuem a tendência significativamente negativa, indicando um decaimento da felicidade em países dessas áreas.

Obs: A região “Unknown” é composta por 21 países nessa análise, de modo que a maioria deles pertence ao Oriente Médio, Norte da África e África-Sub-Saariana.

Previsão de Life Ladder com Modelos de Regressão

A previsão do Life Ladder, indicador que reflete o nível de felicidade e bem-estar de um país, é um desafio importante na análise de dados sociais e econômicos. Neste contexto, a utilização de modelos de regressão, como a Regressão Linear, Random Forest Regressor, Decision Tree e KNN, se mostra relevante para entender as variáveis que influenciam esse índice. A Regressão Linear, Decision Tree e KNN apresentam uma fácil implementação e baixo tempo de processamento, enquanto o Random Forest oferece uma abordagem mais robusta e complexa, capaz de capturar interações não-lineares e variáveis de maior complexidade, por meio de várias árvores de decisão, apresentando um custo computacional

maior. A comparação desses modelos permite uma análise mais profunda sobre sua eficácia e capacidade de capturar padrões nos dados.

Primeiramente, será feito o treinamento dos modelos excluindo a variável ‘Regional indicator’, ou seja, a região a qual o país pertence não será utilizada para prever o índice de felicidade. Após isso, iremos treinar novamente os modelos de Aprendizado de Máquina incluindo a variável de indicador de região. Com isso, podemos comparar os resultados obtidos e concluir se a presença do atributo de região teve algum impacto no desempenho dos modelos, analisado a partir das seguintes métricas:


1. **R²**: Proporção da variância explicada pelo modelo em relação aos dados.
2. **MAE (Mean Absolute Error)**: Erro absoluto médio entre os valores previstos e os valores reais
3. **RMSE (Root Mean Squared Error)**: Erro médio quadrático entre os valores previstos e os reais, penalizando mais fortemente erros maiores

Em ambos os modelos, os valores das métricas foram calculados para cada um dos 10 folds, e as médias de cada métrica representam o desempenho do modelo.

Sem utilizar ‘Regional indicator’				
Modelo de Regressão	R ²	MAE	RMSE	Tempo de Processamento
Regressão Linear	0.76509	0.41326	0.54191	1 segundo
Random Forest	0.86993	0.30191	0.40243	18 segundos
Decision Tree	0.75100	0.40738	0.55719	1 segundo
KNN	0.85937	0.30790	0.41785	1 segundo


Utilizando ‘Regional indicator’				
Modelo de Regressão	R ²	MAE	RMSE	Tempo de Processamento
Regressão Linear	0.78642	0.39107	0.51673	1 segundo
Random Forest	0.88518	0.28312	0.37772	20 segundos
Decision Tree	0.77229	0.39013	0.53263	1 segundo
KNN	0.87997	0.28414	0.38610	1 segundo

Com isso, podemos perceber que a inclusão do indicador regional teve um impacto bastante positivo no desempenho de todos os quatro modelos de Aprendizagem de Máquina implementados. Os gráficos abaixo representam a relação entre os valores previstos pelos modelos com inclusão do indicador regional e os valores reais de Life Ladder.



O modelo Random Forest apresentou um R^2 superior (0.86987) em relação aos outros modelos, com um desempenho muito próximo ao KNN, indicando que ele consegue explicar uma maior parte da variabilidade dos dados. Em termos de erro absoluto médio (MAE) e erro quadrático médio (RMSE), o Random Forest também superou os outros modelos, com desempenho similar ao KNN novamente, sugerindo previsões mais precisas e com menor dispersão em torno dos valores reais. No entanto, enquanto a Random Forest possui o melhor desempenho, o KNN apresenta um desempenho muito semelhante com um custo de processamento bastante melhor. Portanto, a escolha entre esses modelos dependerá da prioridade entre precisão e tempo de execução, com o Random Forest sendo mais adequado para cenários onde a precisão é mais crítica, e o KNN para aplicações que exigem resultados rápidos, ainda com bom desempenho.

A partir do modelo Random Forest, é possível analisar a importância das features na predição do índice de felicidade “Life Ladder”.



Sendo assim, percebe-se que a variável “Log GDP per capita” possui a maior importância nessa previsão. Isso sugere que, ao tentar prever a felicidade das pessoas, o modelo considera principalmente o nível de riqueza ou produção econômica de um país, medido por esse indicador, como um fator importante. Isso reforça a ideia de que a economia de um país tem uma grande correlação com os níveis de felicidade da população.

6. Conclusão

O presente trabalho explorou a base de dados **World Happiness Report (WHR)** para analisar fatores que influenciam os índices de felicidade global e desenvolver modelos preditivos do índice de felicidade (**Life Ladder**) no período de 2007 a 2023. Para isso, foram seguidas diversas etapas, desde o pré-processamento dos dados até a avaliação de modelos de aprendizado de máquina.

Na fase inicial, o pré-processamento incluiu a exclusão de entradas referentes aos anos de 2005 e 2006, além do preenchimento de valores ausentes utilizando a mediana para minimizar o impacto de outliers. Em seguida, foi aplicada a normalização das variáveis numéricas para garantir consistência entre escalas. Também foi realizada uma análise da matriz de correlação, identificando que os atributos mais correlacionados ao índice de felicidade foram **Log GDP per capita**, **Social Support**, **Healthy Life Expectancy**, **Freedom to Make Life Choices**, **Positive Affect** e **Perceptions of Corruption**.

Foi realizada uma análise do índice de felicidade na atualidade, considerando dados do período de 2020 a 2023. Os dados mostram que países como Estados Unidos, Canadá, Austrália e várias nações europeias, incluindo Dinamarca, Finlândia e Noruega, apresentam altos índices de felicidade, com médias acima de 7. Em contrapartida, na América Latina, leste e sudeste asiático, o índice de felicidade é intermediário, em torno de 6. Já a África e o sul da Ásia exibem uma concentração de países com baixos índices de felicidade, destacando-se o Afeganistão com o menor índice global.

Além disso, o estudo analisou os impactos da pandemia de COVID-19, identificando uma ligeira queda média nos índices de felicidade global, mas sem mudanças significativas para a maioria dos países.

Ademais, foi realizada uma análise de tendências de felicidade ao longo do tempo utilizando regressão linear, que revelou coeficientes positivos e negativos representando, respectivamente, aumento ou queda na felicidade de diferentes países. Entre os países com maior crescimento no índice de felicidade, destacam-se Sérvia, Bulgária e Guiné, enquanto Afeganistão, Síria e Líbano apresentaram as maiores quedas.

A análise regional mostrou desigualdades marcantes nas tendências:

- Regiões como **Central and Eastern Europe, Commonwealth of Independent States**, e **East Asia** tiveram tendências predominantemente positivas, indicando um aumento significativo na felicidade ao longo dos anos.
- Em contraste, regiões como **Middle East and North Africa, North America and ANZ**, e **South Asia** apresentaram tendências negativas, sugerindo declínio na felicidade.

Os resultados globais apontaram uma **média de tendência positiva** de 0,0781 e uma **mediana de 0,0614**, sugerindo que a maioria dos países analisados está caminhando para um aumento da felicidade ao longo do tempo, ainda que de forma desigual.

Foram implementados quatro modelos de regressão: **Regressão Linear, Random Forest, Decision Tree** e **KNN** que fazem a predição do índice de felicidade (Life Ladder), utilizando a técnica de validação cruzada com 10 folds (K-Fold) para garantir maior robustez nos resultados. O desempenho dos modelos foi avaliado por métricas como R^2 , MAE, RMSE e tempo de processamento.

O modelo que utiliza a técnica de **Random Forest** apresentou resultados superiores nas métricas R^2 , MAE e RMSE, indicando um desempenho superior em termos de acurácia, seguido pelo **KNN**, que apresentou um desempenho bastante similar ao Random Forest porém com tempo de processamento bastante menor.

A análise da importância das features no modelo de Random Forest e a matriz de correlação destacam o impacto da economia de um país nos níveis de felicidade da população, confirmando achados de estudos anteriores. No entanto, a principal contribuição deste trabalho foi ampliar o escopo temporal da análise e explorar as mudanças em diferentes períodos históricos, como a pandemia.

Como trabalhos futuros, sugere-se:

1. Ampliar o conjunto de modelos de aprendizado de máquina para incluir técnicas avançadas como **Redes Neurais Artificiais** e **Gradient Boosting**.
2. Explorar modelos explicáveis, como **XGBoost com SHAP values**, para entender o impacto de cada variável no índice de felicidade.
3. Incorporar variáveis externas, como indicadores climáticos ou dados socioeconômicos de outras fontes, para enriquecer as análises preditivas.

4. Analisar o índice de felicidade em contextos regionais mais específicos, identificando padrões em subgrupos de países.

Essas abordagens podem oferecer insights adicionais sobre os fatores que promovem a felicidade global e contribuir para políticas públicas mais eficazes.

7. Referências

1. World Happiness Report. Disponível em: <https://worldhappiness.report/about/>. Acesso em: 24 nov. 2024.
2. AKANBI, Kemi; JONES, Yeboah; OLUWADARE, Sunkanmi; NTI, Isaac Kofi. Predicting Happiness Index Using Machine Learning. *In: 2024 IEEE 3RD INTERNATIONAL CONFERENCE ON COMPUTING AND MACHINE INTELLIGENCE (ICMI) 2024*, Anais [...]. : IEEE, 2024. p. 1–5. Disponível em: <http://dx.doi.org/10.1109/icmi60790.2024.10586193>. Acesso em: 25 nov. 2024.
3. JANNANI, Ayoub; SAEL, Nawal; BENABBOU, Faouzia. Predicting Quality of Life using Machine Learning: case of World Happiness Index. *In: 2021 4TH INTERNATIONAL SYMPOSIUM ON ADVANCED ELECTRICAL AND COMMUNICATION TECHNOLOGIES (ISAECT) 2021*, Anais [...]. : IEEE, 2021. p. 1–6. Disponível em: <http://dx.doi.org/10.1109/isaect53699.2021.9668429>. Acesso em: 25 nov. 2024.
4. Darrylljk. The happiness equation: EDA and feature engineering. Kaggle Notebook. Disponível em: <https://www.kaggle.com/code/darrylljk/the-happiness-equation#3.-EDA-and-Feature-Engineering>. Acesso em: 25 nov. 2024.