



Instituto de Ciências Matemáticas e de Computação - ICMC
Disciplina SCC-5948 - CIÊNCIA DE DADOS

Análises de Acidentes em Rodovias Federais em 2024

GABRIEL SERGIO FERREIRA - 16808942
GABRIELE SOUZA VILAS BOAS - 10326221
LUMA GALLACIO GOMES FERREIRA - 9760123

São Carlos - SP
2026

Relatório da disciplina de SCC-5948 -
Ciência de Dados, no 1º. Semestre de
2025, sob orientação da Profa. Roseli
Aparecida Francelin Romero.

RESUMO

Acidentes em rodovias federais brasileiras representam um grave problema socioeconômico. Este trabalho objetivou analisar os fatores associados à letalidade desses acidentes, utilizando dados públicos de 2024 da Polícia Rodoviária Federal (PRF), do Sistema Nacional de Viação (SNV) e do Plano Nacional de Contagem de Tráfego (PNCT). Foi desenvolvido um pipeline robusto para integração, pré-processamento e estruturação dessas bases de dados dispersas. Realizou-se análise exploratória para identificar padrões de acidentalidade. Modelos de classificação multirrótulo (Random Forest, SVM, Regressão Logística, CatBoostClassifier) foram empregados para estimar a severidade dos acidentes ('Com Vítimas Fatais', 'Com Vítimas Feridas', 'Sem Vítimas Fatais'). A importância dos atributos foi avaliada com SHAP e V de Cramér, destacando-se o número de envolvidos e fatores temporais. Apesar dos avanços na estruturação dos dados e identificação de fatores de risco, concluiu-se que os dados disponíveis foram insuficientes para construir um modelo de classificação de severidade generalizável. O estudo contribui com uma base de dados consolidada e análises que podem subsidiar trabalhos futuros na área de segurança viária.

Palavras-chave: Segurança Viária, Modelagem Preditiva, Ciência de Dados

1 INTRODUÇÃO

Os acidentes de trânsito representam um grave problema global, causando cerca de 1,35 milhão de mortes anuais, segundo a OMS, além de impactos econômicos significativos, especialmente em países emergentes, onde podem consumir até 5% do PIB . Cerca de 1,25 milhão de pessoas morrem, no mundo, por ano em acidentes de trânsito (Organização Pan-Americana da Saúde (OPAS), 2024).

Segundo o relatório Acidentes de trânsito nas rodovias federais brasileiras, produzido pelo Instituto de Pesquisa Econômica Aplicada (Ipea), com base nos dados da Polícia Rodoviária Federal (PRF) , em 2014 foram registrados cerca de 169 mil acidentes de trânsito, resultando em aproximadamente 8 mil mortes e 100 mil feridos. Esses incidentes tiveram consequências graves, afetando tanto as finanças públicas quanto a situação econômica das famílias envolvidas. Levando em conta tanto os custos diretos quanto os indiretos, os acidentes de trânsito causaram, em 2014, um impacto econômico de cerca de R\$ 40 bilhões ao Brasil. Desse total, aproximadamente R\$ 12,3 bilhões foram decorrentes de acidentes ocorridos nas rodovias federais (BRASIL. Secretaria de Assuntos Estratégicos da Presidência da República. Instituto de Pesquisa Econômica Aplicada, 2015a).

Dada a relevância das mortes provocadas por esses acidentes, este projeto tem como objetivo principal identificar os fatores mais relacionados à letalidade dos acidentes de trânsito nas rodovias federais brasileiras, a partir dos dados extraídos do sistema de registro de informações da PRF.

Este trabalho está organizado nas seguintes seções:

1. **Trabalhos Relacionados** – Apresenta estudos que utilizaram a mesma base de dados, destacando as técnicas aplicadas e suas contribuições.
2. **Materiais e Métodos** – Detalha o conjunto de dados, as etapas de pré-processamento e exploração, e as configurações dos modelos de aprendizado de máquina.
3. **Experimentos e análises** – Descreve os experimentos realizados, os parâmetros ajustados, os modelos testados e os resultados obtidos.
4. **Conclusão** – Resume os principais resultados e analisa o desempenho das técnicas aplicadas.

2 TRABALHOS RELACIONADOS

Como demonstrado por (SEABRA; SALES, 2023), a aplicação de técnicas de *machine learning* tem-se mostrado promissora para análise de acidentes em rodovias críticas. No estudo sobre a BR-365 em Minas Gerais, os autores utilizaram Redes Neurais Artificiais (RNAs) para predição de frequência de acidentes, comparando métodos de segmentação espacial. Os resultados indicaram que a precisão do modelo aumenta com a extensão do trecho analisado, identificando o segmento entre Uberlândia e Monte Alegre de Minas como o mais crítico. Este trabalho corrobora a relevância da análise preditiva para priorização de intervenções.

O estudo (BROERING *et al.*, 2022) analisou fatores associados à letalidade em rodovias de Santa Catarina aplicando um modelo de regressão logística em dados da PRF. Eles identificaram que condições meteorológicas e falhas infraestruturais tiveram maior impacto na letalidade do que variáveis tradicionalmente associadas a riscos (como pista molhada ou erro humano). O trabalho desafia premissas convencionais ao destacar o papel subestimado de fatores ambientais e viários na gravidade dos acidentes.

Outro estudo, (SCHOLZ; PINHEIRO; SILVA, 2024), analisou a gravidade de acidentes em rodovias brasileiras, nos anos de 2017 a 2022, utilizando bases da PRF e informações sobre preços de veículos. Aplicando os algoritmos e técnicas de explicabilidade, os resultados demonstraram que características dos veículos (como valor financeiro) tiveram maior impacto na previsão da severidade dos acidentes do que fatores ambientais. A abordagem de integrar dados econômicos aos registros de acidentes revelou padrões não explorados anteriormente, destacando o potencial de modelos preditivos para a prevenção de acidentes.

Em 2022, um estudo investigou os desafios logísticos no transporte de soja e milho, principais commodities do agronegócio brasileiro, destacando que a competitividade internacional desses produtos depende criticamente da eficiência do sistema logístico. Pelo trabalho, identificou-se que o transporte hidroviário e ferroviário mostraram-se mais eficientes para longas distâncias, devido à maior capacidade de carga e menor consumo de combustível. No entanto, a infraestrutura brasileira apresenta limitações, como a baixa densidade de ferrovias e hidrovias e a precariedade da malha rodoviária (apenas 12,4% pavimentada). O estudo concluiu que o país precisa priorizar investimentos em infraestrutura logística estruturada, especialmente em ferrovias e hidrovias (SOLIANI, 2022).

Por último, um estudo analisou os fatores relacionados à severidade de acidentes em rodovias no Brasil utilizando um modelo de regressão logística. Os autores classificaram os acidentes em três níveis: sem lesões, com feridos ou fatais. Os principais resultados indicaram que: (1) envolvimento de pedestres foi o fator mais impactante na gravidade dos acidentes; (2) condições que aumentam a velocidade (como clima

seco e baixo tráfego) elevaram o risco de acidentes graves; e (3) a severidade variou sazonalmente, com picos em agosto e novembro. O estudo também destacou a falta de padronização nacional nos registros de acidentes e a necessidade de integrar bancos de dados de trânsito e saúde para melhorar políticas públicas de segurança viária (FRANCESCHI *et al.*, 2022).

Diante da relevância do tema investigado, o presente trabalho delinea os seguintes objetivos:

1. Mapear e caracterizar acidentes nas rodovias federais brasileiras, identificando padrões de ocorrência e gravidade.;
2. Determinar os principais fatores (condições da via, clima, veículos, perfil da vítima) que se correlacionam com a ocorrência e a gravidade dos acidentes;
3. Iniciar o desenvolvimento de um modelo capaz de estimar a gravidade dos acidentes.

Com isso, elaboramos as seguintes hipóteses:

1. Quais rodovias têm mais acidentes?
2. Quais trechos apresentam maior densidade de acidentes?
3. Pessoas mais jovens do sexo masculino estão envolvidos em mais acidentes?
4. Acidentes são mais graves durante o período noturno?

3 MATERIAIS E MÉTODOS

Para a elaboração deste estudo, foram analisados trechos de rodovias brasileiras, com ênfase na BR-381, uma rodovia federal. Também conhecida como Rodovia Fernão Dias, a BR-381 é uma das principais vias federais do Brasil, com aproximadamente 1.100 km de extensão, ligando São Paulo (SP) a Belo Horizonte (MG). A rodovia atravessa regiões de relevante importância industrial e agrícola, mas enfrenta graves desafios de segurança viária, com uma média de 200 mortes por ano, segundo dados da Polícia Rodoviária Federal (PRF). Esses fatores tornam a BR-381 um objeto de estudo prioritário para pesquisas sobre segurança no trânsito e para o desenvolvimento de políticas públicas eficazes na redução de acidentes. A Figura 1 ilustra o trecho da rodovia em análise.

Figura 1 – Rodovia BR-381.



Fonte: Fundação Wikimedia (2025)

3.1 DATASET

Os dados utilizados nesse estudo foram obtidos através dos portais de Dados Abertos de órgãos governamentais do Governo Federal Brasileiro. As bases utilizadas, com os respectivos órgãos governamentais responsáveis pela sua emissão, foram:

1. **PRF Acidentes 2024**, da Polícia Rodoviária Federal (PRF)
2. **PNCT Tráfego 2023**, do Plano Nacional de Contagem de Tráfego (PNCT)
3. **SNV Malha Rodoviária 202401A**, do Sistema Nacional de Viação (SNV)

As análises conduzidas no estudo levaram em consideração a junção das três bases, de modo que fosse possível realizar um mapeamento exaustivo (perante ao SNV) dos trechos e criticidades de acidentalidade rodoviária no Brasil, considerando dinâmicas de tráfego.

Para padronizar, preparar e mesclar as informações, foi desenvolvido um pipeline de pré-processamento robusto, de modo que fosse possível gerar visões em diferentes níveis de agregação. A visão geral deste pipeline é apresentada na Figura 2.




Figura 2 – Visão Geral do Pipeline de Pré-Processamento

Nas subseções a seguir, apresentam-se as características básicas das bases utilizadas, tal como das operações de pré-processamento nelas realizadas.

3.1.1 PRF ACIDENTES

Os dados de acidentalidade da Polícia Rodoviária Federal foram retirados dos Dados Abertos da PRF. Esses conjuntos de dados, fornecidos em formato CSV conforme as diretrizes da Política de Dados Abertos do Executivo Federal (Decreto nº

8.777/2016), contêm registros detalhados de acidentes ocorridos nas rodovias federais brasileiras (Polícia Rodoviária Federal, 2024).

Utilizamos as informações da base "Acidentes 2024 (Agrupados por pessoa - Todas as causas e tipos de acidentes)", a qual possui um total de 603.215 registros, com 37 colunas para cada registro. Este número de registros não reflete o número de acidentes, mas sim o número de registros no nível mais granular da base (a base apresenta um registro único por acidente, envolvido, tipo de acidente e causa de acidente).

A utilização de uma base de granularidade alta permite a definição de pipelines de agregação dinâmicos onde, para cada visão a ser analisada, estruturamos a base necessária. A seguir segue um exemplo descritivo de alguns dos casos de uso em diferentes granularidades:

- Acidentes (número de acidentes, trechos críticos, características de acidentes, etc.)
- Envolvido (perfil dos envolvidos, como idade, gênero, estado físico, etc.)
- Veículo (mix de veículos, veículos com mais envolvidos, veículos mais letais, etc.)
- Outras visões são possíveis (ex. tipo de acidente, causa de acidente, etc.)

Na Figura 3 apresenta-se um uso da API de pré-processamento desenvolvida, assim como um exemplo de agregação final a nível de **envolvidos**. Cinco exemplos de implementação de funções dessa API, utilizando a biblioteca Pandas, são apresentados na Figura 4.

- *fillna* (imputação de valores ausentes)
- *operator[]* (filtro)
- *astype* (conversão de tipagem)
- *.str.replace* (manipulação de *strings*)

O resultado do emprego deste exemplo de pipeline (agregação por envolvidos) é apresentado nas Tabelas 1 e 2.

A base final é uma base menor (apenas 178.619 linhas) mas que representa um **envolvido** de maneira única - ao contrário da anterior que representava envolvidos redundantes para diferentes tipos de acidente e causas de acidente. Essa transformação também é responsável por garantir que todas as colunas estão completamente preenchidas, tipificadas e renomeadas para conformidade com o restante do pipeline.

```

acidentes_prf_p_desagg = (
    acidentes.builder().start_building(data=acidentes_prf.copy())
        .padronizar_colunas()
        .desprezar_rodovias_ausentes()
        .imputar_envolvidos_nao_identificados()
        .imputar_veiculos_nao_identificados()
        .formatar_acidente_id()
        .formatar_rodovia_id()
        .formatar_ano_mes_dia()
        .formatar_quilometragem()
        .inferir_ano_mes()
        .desprezar_classificacao_acidente_nulas()
        .implodir_tipo_veiculo()
).data

acidentes_envolvidos_prf_p_agg = (
    acidentes.builder().start_building(data=acidentes_prf_p_desagg.copy())
        .agregar_envolvidos()
).data

```

Figura 3 – Pipeline de Agregação a nível Envolvido

```

def imputar_veiculos_nao_identificados(self):
    self.data[self.veiculo_id] = self.data[self.veiculo_id].fillna(-1).astype(int)
    self.data[self.tipo_veiculo] = self.data[self.tipo_veiculo].fillna("Veiculo Nao Identificado")
    self.data[self.ano_fabricacao_veiculo] = self.data[self.ano_fabricacao_veiculo].fillna(-1).astype(int)
    return self

def formatar_acidente_id(self):
    self.data[self.acidente_id] = self.data[self.acidente_id].astype(int)
    return self

def formatar_rodovia_id(self):
    self.data[self.rodovia_id] = 'BR-' + self.data[self.rodovia_id].astype(int).astype(str)
    return self

def formatar_ano_mes_dia(self):
    self.data[self.ano_mes_dia] = self.data[self.ano_mes_dia].str.replace('-', '').astype(int)
    self.data['ano_mes_dia_dt'] = pd.to_datetime(self.data['ano_mes_dia'], format='%Y%m%d', errors='coerce')
    return self

def formatar_quilometragem(self):
    self.data[self.km] = self.data[self.km].str.replace(',', '.').astype(float)
    return self

```

Figura 4 – Exemplo de Implementação da API com Pandas

Tabela 1 – PRF Acidentes Crua

Coluna	Nulos
id	603.215
pesid	545.574
km	601.867
br	601.867
id_veiculo	583.643
tipo_veiculo	583.643
estado_fisico	545.574
...	...

Tabela 2 – Pós Agregação por Acidentes

Coluna	Nulos
envolvido_id	178.619
acidente_id	178.619
acidente_rodovia_id	178.619
acidente_km	178.619
veiculo_id	178.619
veiculo_tipo_veiculo	178.619
estado_fisico	178.619
...	...

3.1.2 SNV MALHA RODOVIÁRIA

Os dados da malha rodoviária federal foram obtidos a partir do Sistema Nacional de Viação (SNV), disponibilizado pelo Departamento Nacional de Infraestrutura de Transportes (DNIT). O conjunto representa a geografia oficial das rodovias federais, estaduais e municipais do Brasil, conforme instituído pela Lei nº 12.379/2011.

A principal finalidade deste conjunto foi estruturar uma malha georreferenciada de alta precisão sobre a qual pudéssemos mapear eventos de acidentalidade, e incidência desses eventos sobre trechos. A granularidade nativa do SNV é por trecho contínuo de rodovia (descrito unicamente por seu identificador), contemplando dados sobre tipo de trecho e quilometragem (inicial e final), além da geometria.

O pipeline de pré-processamento da malha foi o mais simples entre as três bases utilizadas, pois já se encontrava suficientemente adequada às análises propostas. Realizamos apenas quatro etapas:

1. Padronização das colunas (conforme dicionário em anexo)
2. Formatação da coluna de identificador de rodovia (para notação BR-XYZ)
3. Filtro de Tipo de Trecho (selecionamos apenas o Eixo Principal)
4. Mescla com Bases de Tráfego

A execução desse pipeline se dá de maneira muito similar ao das demais bases, e é apresentada na Figura 5, com implementação dos métodos de formatação, filtro e mesclagem (via Pandas) apresentados na Figura 6.

O racional de implementação do método de mesclagem com a base de tráfego (*merge_trafego*) será melhor discutido na sessão subsequente.

```
malha_rodoviaria_snv_p = (
    malha_rodoviaria.builder().start_building(data=malha_rodoviaria_snv.copy())
    .padronizar_colunas()
    .formatar_rodovia_id()
    .filtrar_tipo_trechos(tipo_trechos=tipo_trechos)
    .merge_trafego(
        trafego_por_trecho=trafego_pnct_trecho,
        trafego_por_ul=trafego_pnct_ul,
        trafego_por_uf=trafego_pnct_uf,
        trafego_por_rodovia=trafego_pnct_rodovia,
    )
).data
```

Figura 5 – Pipeline de Malha Rodoviária SNV

```
def padronizar_colunas(self):
    cols_mapping = {
        'id_trecho': self.trecho_id,
        'vl_br': self.rodovia_id,
        'sg_uf': self.sigla_uf,
        'ul': self.unidade_local,
        'nm_tipo_tr': self.tipo_trecho,
        'ds_legenda': self.tipo_pista,
        'sg_legenda': self.sigla_tipo_pista,
        'ds_tipo_ad': self.tipo_admin,
        'vl_km_inic': self.inicio_trecho,
        'vl_km_fina': self.final_trecho,
        'vl_extensa': self.extensao_trecho,
    }
    self.data = self.data.rename(columns=cols_mapping)
    return self

def formatar_rodovia_id(self):
    self.data[self.rodovia_id] = 'BR-' + self.data[self.rodovia_id].astype(int).astype(str)
    return self

def filtrar_tipo_trechos(self, tipo_trechos = ['Eixo Principal']):
    self.data = self.data[self.data[self.tipo_trecho].isin(tipo_trechos)]
    return self
```

Figura 6 – Exemplo de Implementação Malha

3.1.3 PNCT TRÁFEGO

Os dados de volume de tráfego foram obtidos a partir do Painel de Contagem Volumétrica (PNCT), mantido pelo Departamento Nacional de Infraestrutura de Transportes (DNIT). Esta base apresenta medições periódicas de volume médio diário (VMD) ao longo da malha rodoviária federal, realizadas por meio de postos de contagem ao longo do ano de 2023 (mais recente disponibilizada).



Figura 7 – Posicionamento Geográfico dos *Count Locations* em 2023 - retirada de (DNIT, 2024)

A ficha completa dos atributos do conjunto de dados está documentada no Apêndice

A principal finalidade de incorporar a informação de tráfego foi prover uma medida de exposição ao risco, baseada no volume de tráfego nos trechos analisados. A gra-

nularidade nativa da base é por *Count Location*, definido como segmentos da rede rodoviária com fluxo conhecido (DNIT, 2024). O mapeamento dos *Count Locations* empregados na metodologia de 2023 é exibido na Figura 7

A métrica de fluxo empregada pela metodologia do PNCT é o Valor Médio Diário Anual (*VMDa*), calculado por categoria de veículo e *Count Location*, a partir da coleta de dados de diversas fontes. As categorias de veículos utilizadas pelo PNCT não correspondem às mesmas categorias definidas pela PRF, e tampouco correspondem às categorias de interesse para nossa análise - exigindo uma etapa de processamento dedicada para o devido agrupamento desses valores de tráfego.

Matematicamente, podemos entender o cálculo do *VMDa* de cada *Count Location* como sendo

$$VMDa = \frac{\sum VMD}{n_{dias}} = \frac{\sum medicoes\ dirias}{n_{medicoes\ por\ dia} \cdot n_{dias}}$$

Apesar de muitos trechos possuírem fluxo mapeado, a base de tráfego não apresenta informações de maneira exaustiva para toda a rede rodoviária federal. Inclusive, em alguns casos, o mapeamento de fluxo é feito em apenas um único sentido, mesmo sendo um trecho de dois sentidos.

```
def imputar_vmda_ausentes_com_sentido_oposto(self):
    self.data[self.vmda_total_cresc] = self.data[self.vmda_total_cresc].fillna(self.data[self.vmda_total_decresc])
    self.data[self.vmda_comerciais_cresc] = self.data[self.vmda_comerciais_cresc].fillna(self.data[self.vmda_comerciais_decresc])
    self.data[self.vmda_passutil_cresc] = self.data[self.vmda_passutil_cresc].fillna(self.data[self.vmda_passutil_decresc])
    self.data[self.vmda_motos_cresc] = self.data[self.vmda_motos_cresc].fillna(self.data[self.vmda_motos_decresc])

    self.data[self.vmda_total_decresc] = self.data[self.vmda_total_decresc].fillna(self.data[self.vmda_total_cresc])
    self.data[self.vmda_comerciais_decresc] = self.data[self.vmda_comerciais_decresc].fillna(self.data[self.vmda_comerciais_cresc])
    self.data[self.vmda_passutil_decresc] = self.data[self.vmda_passutil_decresc].fillna(self.data[self.vmda_passutil_cresc])
    self.data[self.vmda_motos_decresc] = self.data[self.vmda_motos_decresc].fillna(self.data[self.vmda_motos_cresc])
    return self
```

Figura 8 – Imputação de Tráfego Ausente pelo sentido oposto *VMDa*

Para resolver esse problema, foi empregada a estratégia de imputação dos sentidos ausentes pelo tráfego do sentido oposto, no mesmo trecho, caso haja (sob a premissa de que será similar ao do sentido original), conforme Figura 8. Se o sentido oposto não for um sentido válido para a rodovia, ele não será incorporado na mescla com o SNV, não havendo problema de mapeamento de tráfego inexistente.

O pipeline de processamento da base de tráfego levou em consideração, por fim, a definição de quatro possíveis agregações para imputação dinâmica de trechos sem *VMDa* no SNV. As granularidades das agregações definidas e o racional de imputação por respecagem foram:

1. Agregação por Trecho - prioridade máxima, trecho com fluxo mapeado
2. Agregação por Rodovia e Unidade Local (UL) - se trecho não tiver fluxo mapeado, repesca pela média da (rodovia, UL)
3. Agregação por Rodovia e Unidade Federativa (UF) - se repescagem por município falhar, repesca pela média da (rodovia, UF)
4. Agregação por Rodovia - se os demais falharem, repesca pela média da rodovia

Na Figura 9 apresenta-se a invocação do pipeline de agregação por trecho, a ser incluído na junção com a base da malha rodoviária federal.

```
trafego_pnct_trecho = (  
    trafego.builder().start_building(data=trafego_pnct.copy())  
        .padronizar_colunas()  
        .formatar_rodovia_id()  
        .formatar_kms()  
        .imputar_unidade_local_nao_identificada()  
        .inferir_volume_medio_diario_anual()  
        .imputar_vmda_ausentes_com_sentido_oposto()  
        .desprezar_vmda_ausentes()  
        .agregar_vmda_por_trecho()  
) .data
```

Figura 9 – Pipeline da base de tráfego com agregação por trecho

4 EXPERIMENTOS E ANÁLISES

Esta seção analisa os acidentes sob duas perspectivas complementares: inicialmente examina as características dos sinistros através de abordagens espaciais e temporais, considerando trechos críticos, perfis dos envolvidos e padrões de ocorrência; em seguida, aplica técnicas de aprendizado de máquina para modelar os fatores de risco e desenvolver ferramentas preditivas específicas para esta rodovia. Os modelos foram feitos limitando o conjunto de dados para a BR-381. Com isso, é possível integrar análises descritivas e preditivas.

4.1 ANÁLISE EXPLORATÓRIA

4.1.1 ACIDENTES




Figura 10 – Distribuição Geográfica de Acidentes em 2024 (absoluta)

Nossa metodologia foi capaz de mapear 72.847 dos 72.970 (99,83%) dos acidentes ocorridos em 2024. A maioria dos acidentes resultou em vítimas ilesas ou com ferimentos leves, mas aproximadamente **5.770 óbitos** foram contabilizados, o que reforça o elevado custo humano do trânsito brasileiro.

A severidade dos acidentes varia substancialmente em função de fatores como horário, condições meteorológicas, tipo de pista e perfil dos envolvidos. Esses aspectos serão detalhados nas próximas seções do relatório, com foco na BR-381, uma das rodovias federais mais letais do país.

A análise inicial da acidentalidade em rodovias federais revela uma **concentração expressiva de acidentes na região Sudeste**, especialmente nos estados de São Paulo, Minas Gerais e Paraná. A Figura 10 evidencia visualmente esse padrão com base em dados absolutos de ocorrência. Essa concentração pode ser atribuída à elevada densidade populacional e à maior circulação de veículos nessas regiões, além da presença de importantes corredores logísticos.

Além disso, observa-se que os principais corredores longitudinais (como as BR-101, BR-116 e BR-381) aparecem entre os trechos com maior número de ocorrências, sustentando a hipótese de que o volume de tráfego e a importância econômica dos corredores estão fortemente relacionados à frequência de acidentes.

Contudo, ao normalizar os dados pelo comprimento das rodovias, obtém-se uma visão mais precisa da periculosidade de uma rodovia, calculando a **densidade de acidentes**, definida pela quantidade de ocorrências por quilômetro rodado. A Tabela 3 apresenta essa análise, revelando que a **BR-381**, embora com extensão relativamente curta, apresenta uma densidade de 2,92 acidentes por km — superior às BR-101 e BR-116, mesmo com menor número absoluto de acidentes.

Tabela 3 – Ocorrências e Densidade de Acidentes por Rodovia em 2024

Rodovia	Extensão (km)	# Acidentes	Densidade
BR-101	4.587	12.778	2,79
BR-116	4.502	11.454	2,55
BR-381	1.188	9.069	2,92
BR-40	1.139	8.645	2,95
BR-153	3.589	7.333	0,76
...	...	...	...
Total	128.240	72.847	0,67

Rodovias como a BR-40 e BR-381 se destacam por apresentarem densidades superiores a 2,9, valor **quase cinco vezes acima da média nacional**, que é de 0,67. Isso indica que, proporcionalmente, esses trechos concentram uma carga de risco muito elevada, mesmo quando seu volume total de acidentes é menor que em rodovias mais longas.

Acidentes Ponderados por Tráfego

Ao incorporar o volume de tráfego como fator de exposição, é possível construir uma visão mais justa e comparável do risco de acidentalidade. A Figura 11 evidenciam que, após ponderação pelo volume médio diário de veículos (VMD), surgem **novos trechos críticos** fora do eixo tradicional Sul-Sudeste.




Figura 11 – Trechos Críticos com Ponderação vs Sem Ponderação

Trechos no interior do Nordeste, Centro-Oeste e regiões da BR-153 e BR-230 revelam alta letalidade **relativa ao tráfego**, destacando pontos com infraestrutura potencialmente deficiente, baixa cobertura de serviços de emergência ou geometria viária desfavorável, mesmo em locais com menor fluxo veicular.

Esse ajuste também mostra que alguns trechos anteriormente destacados pelo volume absoluto deixam de parecer críticos quando o fluxo é levado em conta, o que reforça a necessidade de métricas normalizadas para priorização de políticas públicas.

Discussão

A abordagem hierárquica — absoluto, densidade, tráfego — revela como a interpretação dos dados muda significativamente conforme a **granularidade e a ponderação empregadas**.


- Em valores absolutos, as regiões mais desenvolvidas se destacam por volume puro.
- Pela densidade, surgem rodovias de menor extensão, mas com altíssimo risco por km, como a BR-381.
- Ao considerar o tráfego, trechos interioranos com baixa visibilidade ganham destaque como **pontos críticos ignorados por políticas públicas tradicionais**.

Essas análises reforçam a importância de utilizar múltiplas métricas simultaneamente. A priorização de intervenções em segurança viária **não deve se basear apenas no volume bruto de acidentes**, mas deve também considerar **indicadores de densidade e risco proporcional ao tráfego**. Essa abordagem orienta decisões mais justas, eficazes e financeiramente otimizadas.

4.1.2 ENVOLVIDOS

Na Figura 1 vemos que brasil registrou 5.770 mortes por acidentes rodoviários em vias federais em 2024. Para modelar uma classificação de fatalidade de acidentes, precisaremos levar em consideração o desbalanceamento de óbitos e vivos

Figura 1 – Frequência de acidentes por escala de severidade dos acidentados.



Fonte: autores


Na Figura 2 temos o perfil de acidentados por idade da vítima. Calculamos os Momentos e vimos que os valores indicam uma distribuição levemente assimétrica à direita ($\text{skew} = 0.36$), com a média (39.24) maior que a mediana (38.00), sugerindo a presença de valores altos que puxam a média para cima. A curtose próxima de zero (0.15) mostra que os dados têm um achatamento similar ao da distribuição normal. A moda (29.00) é o valor mais frequente, mas está abaixo da mediana, reforçando a assimetria à direita, enquanto o desvio padrão (15.53) indica uma dispersão moderada em torno da média.

A análise da Figura 3 revela uma predominância masculina entre os acidentados, com as mulheres representando apenas 25% dos casos. Para explicar essa disparidade, levantamos duas hipóteses de fatores independentes: (1) os homens podem constituir a maioria dos condutores, ou (2) apresentam maior propensão a comportamentos de risco no trânsito em comparação com as mulheres.

Nota-se na Figura 4 que a distribuição de idade dos acidentados é parecida para todos os estados físicos, com média em torno de 40 anos, mas apresenta menos outliers para vítimas que vieram a óbito.


Vemos a frequência por período do dia na Figura 5. Observa-se que a madrugada apresentou a maior proporção de acidentes com vítimas fatais (25,9%), seguida pela noite (16,1%). Em contraste, os acidentes com vítimas feridas predominaram durante a manhã (81,7%) e tarde (80,4%), enquanto os sem vítimas foram mais frequentes na

Figura 2 – Frequência de acidentes por idade.



Fonte: autores


Figura 3 – Frequência de acidentes por Sexo.



Fonte: autores

madrugada (11,3%) e noite (9,4%), indicando que os períodos noturnos, especialmente a madrugada, estão associados a acidentes mais graves, apesar do menor volume

Figura 4 – Tipos de acidentes por boxplot.




Fonte: autores

total.


Na Figura 6 temos os acidentes por condição meteorológica. Vemos que a grande maioria ocorre ao céu claro. A condição Nevoeiro/Neblina tem maior proporção de fatalidades, apesar do número absoluto ser baixo.

Figura 5 – Tipos de acidentes por período do dia.



Fonte: autores

Figura 6 – Tipos de acidentes por condição meteorológica.



Fonte: autores


4.2 MODELAGEM DE FATALIDADE EM ACIDENTES

4.2.1 SELEÇÃO DE ATRIBUTOS

Foi desenvolvida e avaliada uma modelagem piloto visando a classificação da severidade de acidentes. Implementou-se um modelo de classificação *multi-label* para categorizar os acidentes em 'Com Vítimas Fatais', 'Com Vítimas Feridas' e 'Sem Vítimas Fatais'.

Para compreender a influência das variáveis de entrada no desempenho do modelo, utilizou-se a técnica SHAP (*SHapley Additive exPlanations*), que permitiu identificar os atributos de maior importância preditiva. A análise de interpretabilidade do modelo utilizando SHAP, conforme visualizado na Figura 7, permitiu identificar a hierarquia de importância das variáveis na predição da severidade dos acidentes. O atributo `num_envolvidos` aparece como o fator de maior impacto individual nas previsões do modelo, superando todas as outras variáveis. Fatores temporais, como `horario` e `fase_dia`, também demonstraram relevância.


Figura 7 – SHAP – Distribuição de Importâncias.



Fonte: autores

Considerando que o conjunto de dados era composto majoritariamente por variáveis categóricas, foi empregada a estatística V de Cramér para avaliar o grau de associação entre pares de *features*. A matriz de correlação resultante, ilustrada na Figura 8, evidencia que, em geral, as associações entre as variáveis são fracas, com a maioria dos valores de V de Cramér sendo relativamente baixos. Apesar disso, identificaram-se alguns pontos de associação mais notáveis. Destacam-se as inter-relações observadas para a variável *causa_principal*, as associações envolvendo variáveis temporais como *horario* e *periodo* (que, como esperado, também mostraram forte associação entre si e com *fase_dia*), e também algumas associações relacionadas ao *tracado_via*.

Figura 8 – Matriz de correlação de Crámer's V.



Fonte: autores

4.2.2 MODELOS

Para abordar o problema de classificação proposto, onde a maioria das variáveis preditoras são categóricas, os seguintes modelos foram utilizados:

1. Random Forest: Um método de ensemble baseado em árvores de decisão, robusto e amplamente utilizado em tarefas de classificação.
2. Support Vector Machine (SVM): Um classificador baseado na construção de hiperplanos ótimos em um espaço multidimensional. Para dados categóricos, geralmente requer pré-processamento como one-hot encoding.
3. Regressão Logística (*Logistic Regression*): Um modelo linear generalizado comumente usado para classificação binária, mas extensível a cenários multiclasse. Também pode requerer pré-processamento para features categóricas.
4. CatBoost Classifier: Um algoritmo de *gradient boosting* que se destaca por seu tratamento nativo e eficiente de variáveis categóricas, minimizando a necessidade de pré-processamento extensivo e frequentemente alcançando alto desempenho.

Com o objetivo de avaliar o impacto da etapa de seleção de atributos no desempenho preditivo dos modelos, foram testados três subconjuntos distintos de *features*, gerados a partir de diferentes abordagens:

1. **Features 1 (Baseado em SHAP):** Seleção das variáveis mais importantes identificadas através da análise dos valores SHAP (SHapley Additive exPlanations), conforme observado na Figura 7 .
2. **Features 2 (Baseado em V de Cramér):** Seleção guiada pela análise da matriz de correlação V de Cramér (Figura 8), visando selecionar variáveis com maior associação à classe alvo e remover redundâncias.
3. **Features 3 (Seleção Manual):** Um conjunto de features selecionado manualmente com base na análise exploratória prévia dos dados.

Cada um dos quatro modelos de classificação (Random Forest, SVM, Regressão Logística e CatBoostClassifier) foi treinado e avaliado utilizando cada um desses três subconjuntos de features (*features_1*, *features_2* e *features_3*). As métricas de desempenho resultantes, incluindo Acurácia Ponderada e a Área Sob a Curva ROC (AUC) para cada uma das classes de severidade (Fatais, Feridas, Sem Vítimas), foram comparadas para determinar a combinação de modelo e conjunto de features mais eficaz. Os resultados detalhados desta análise comparativa são apresentados na Tabela 4.

Tabela 4 – Comparativo de desempenho dos modelos de classificação utilizando diferentes subconjuntos de features selecionadas. Métricas apresentadas: Acurácia Ponderada e AUC por classe (Fatais, Feridas, Sem Vítimas).

Feature Set	Modelo	Acc. Ponderada	AUC Fatais	AUC Feridas	AUC S. Vítimas
Feat.1 (SHAP)	Random Forest	0.3940	0.72	0.65	0.67
Feat.1 (SHAP)	SVM	0.4612	0.70	0.63	0.67
Feat.1 (SHAP)	Regressão Logística	0.5318	0.77	0.63	0.67
Feat.1 (SHAP)	CatBoost	0.4616	0.67	0.59	0.64
Feat.2 (Cramér's V)	Random Forest	0.3982	0.78	0.65	0.67
Feat.2 (Cramér's V)	SVM	0.4776	0.80	0.61	0.64
Feat.2 (Cramér's V)	Regressão Logística	0.5143	0.75	0.62	0.66
Feat.2 (Cramér's V)	CatBoost	0.4531	0.72	0.61	0.68
Feat.3 (Manual)	Random Forest	0.4069	0.71	0.63	0.64
Feat.3 (Manual)	SVM	0.4685	0.68	0.63	0.68
Feat.3 (Manual)	Regressão Logística	0.5499	0.72	0.64	0.67
Feat.3 (Manual)	CatBoost	0.4364	0.59	0.57	0.63

Em uma fase exploratória, diversas abordagens foram testadas visando aprimorar ou avaliar a robustez dos resultados. Foi investigado o impacto do desbalanceamento de classes nos dados, aplicando-se tanto técnicas de sobreamostragem (*oversampling*) com o algoritmo SMOTE (*Synthetic Minority Over-sampling Technique*) quanto de subamostragem (*undersampling*) da classe majoritária. Adicionalmente, explorou-se o ajuste de diferentes configurações de hiperparâmetros dos modelos (como *max_depth*

e `min_samples_leaf`), e utilizou-se validação cruzada K-folds para uma avaliação mais robusta do desempenho. Outras análises exploratórias incluíram a transformação da variável alvo de multirrótulo para um formato binário (Com fatalidade vs. Sem fatalidade) e a avaliação do desempenho do modelo em diferentes escopos de dados (restringindo à rodovia BR-381 versus utilizando todas as rodovias). Estas investigações foram conduzidas de forma exploratória para entender a sensibilidade dos resultados às diferentes escolhas metodológicas e identificar possíveis caminhos para otimização futura.

5 CONCLUSÕES

Este estudo demonstrou que, embora as bases de dados públicas sobre acidentalidade rodoviária no Brasil estejam dispersas, elas contêm informações valiosas. Através de um extenso processo de estruturação e enriquecimento desses dados, foi criada uma base sólida que possibilita o desenvolvimento de trabalhos futuros na área. Um avanço significativo foi alcançado na identificação de trechos críticos em rodovias federais, utilizando uma abordagem que pondera os acidentes pelo volume de tráfego. No entanto, apesar das diversas tentativas, não foi possível desenvolver um modelo de classificação de acidentes que pudesse ser generalizado de forma eficaz com os dados disponíveis atualmente, indicando a necessidade de informações adicionais ou abordagens distintas para essa tarefa específica.

Para dar continuidade e aprofundar a compreensão da acidentalidade rodoviária, recomenda-se a expansão das fontes de dados, incluindo bases de outras dimensões, como as provenientes da Agência Nacional de Transportes Terrestres (ANTT). Sugere-se também a incorporação de variáveis de tráfego diretamente nos modelos de classificação, buscando superar as limitações encontradas no presente estudo. Além disso, explorar outras tarefas de classificação, como a distinção entre acidentes com e sem culpabilidade identificada, representa uma linha promissora para investigações futuras.

REFERÊNCIAS

BRASIL. Secretaria de Assuntos Estratégicos da Presidência da República. Instituto de Pesquisa Econômica Aplicada. **Acidentes de trânsito nas rodovias federais brasileiras: caracterização, tendências e custos para a sociedade**. 2015a. Relatório técnico. Disponível em: <http://www.ipea.gov.br/portal/index.php?option=com_content&view=article&id=26277>.

BROERING, W. *et al.* Fatores associados à incidência de Óbitos em acidentes de trânsito nas rodovias federais do estado de santa catarina, brasil. **Revista Transporte y Territorio**, 11 2022.

DNIT, D. N. de Infraestrutura de T. **Nota Técnica No 004/2024: Síntese da Metodologia para Estimativa do Volume Médio Diário Anual (VMDa) 2023 em Toda a Malha Rodoviária Federal Pavimentada**. Brasília, DF, 2024. Disponível em: <<https://servicos.dnit.gov.br/dadospnct/Modelagem>>. Acesso em: mai. 2025.

FRANCESCHI, L. *et al.* Factors related to highway crash severity in brazil through a multinomial logistic regression model. **TRANSPORTES**, v. 30, p. 2566, 04 2022.

FUNDAÇÃO WIKIMEDIA. **BR-381 — Wikipedia, a enciclopédia livre**. 2025. [Online; acesso em 10 abr. 2025]. Disponível em: <<https://pt.wikipedia.org/wiki/BR-381>>.

Organização Pan-Americana da Saúde (OPAS). **Segurança no trânsito**. 2024. Disponível em: <<https://www.paho.org/pt/topicos/seguranca-no-transito>>.

Polícia Rodoviária Federal. **Dados Abertos da PRF**. 2024. Acesso em: 10 abr. 2025. Disponível em: <<https://www.gov.br/prf/pt-br/acesso-a-informacao/dados-abertos/dados-abertos-da-prf>>.

SCHOLZ, J. C. W.; PINHEIRO, Y. P.; SILVA, T. H. Predicting highway accident severity in brazil: Environmental factors and vehicle features. In: **2024 20th International Conference on Distributed Computing in Smart Systems and the Internet of Things (DCOSS-IoT)**. [S.l.: s.n.], 2024. p. 740–747.

SEABRA, L. O.; SALES, V. F. **Aplicação de redes neurais artificiais na predição da acidentalidade viária na rodovia BR-365**. Trabalho de Conclusão de Curso, 2023. Bacharelado em Engenharia de Agrimensura e Cartográfica. Orientadora: Prof.^a Dra. Luciany Oliveira Seabra; Coorientador: Me. Vinícius Ferreira Sales.

SOLIANI, R. Logistics and transportation in brazilian agribusiness: The flow of grain production. **Journal of Economics Business and Management**, v. 10, p. 210–219, 05 2022.

APÊNDICE A — DICIONÁRIO DE VARIÁVEIS PRF ACIDENTES

Nome Original	Nome Padronizado	Descrição
id	acidente_id	ID do acidente
pesid	envolvido_id	ID do envolvido
br	rodovia_id	Código da rodovia
data_inversa	ano_mes_dia	Data do acidente
horario	horario	Horário do acidente
uf	sigla_uf	Estado da ocorrência
km	km	Quilômetro do evento
causa_principal	causa_principal	Causa mais provável
causa_acidente	causa_acidente	Causa do acidente
ordem_tipo_acidente	ordem_tipo_acidente	Ordem tipo acidente
tipo_acidente	tipo_acidente	Tipo de acidente
classificacao_acidente	classificacao_acidente	Gravidade do acidente
fase_dia	fase_dia	Momento do dia
sentido_via	sentido_via	Sentido da via
condicao_metereologica	condicao_metereologica	Clima no momento
tipo_pista	tipo_pista	Tipo de pista
tracado_via	tracado_via	Traçado da via
uso_solo	uso_solo	Uso do solo
id_veiculo	veiculo_id	ID do veículo
tipo_veiculo	tipo_veiculo	Tipo do veículo
marca	marca	Marca do veículo
ano_fabricacao_veiculo	ano_fabricacao_veiculo	Ano de fabricação
tipo_envolvido	tipo_envolvido	Tipo do envolvido
estado_fisico	estado_fisico	Estado físico pessoa
idade	idade	Idade do envolvido
sexo	sexo	Sexo do envolvido
ilesos	ilesos	Envolvidos ilesos
feridos_leves	feridos_leves	Envolvidos feridos leves
feridos_graves	feridos_graves	Envolvidos feridos graves
mortos	mortos	Envolvidos mortos
latitude	latitude	Latitude do acidente
longitude	longitude	Longitude do acidente
regional	regional	Regional da PRF
delegacia	delegacia	Delegacia responsável
uop	uop	Unidade operacional PRF